

Phénotypage digital: prédire le stress et l'humeur futurs grâce au téléphone intelligent

Octobre numérique 2021, organisé par IVADO

présenté par **Thierry Jean**, étudiant M.Sc. Sciences biomédicales, UdeM
supervisé par **Pierre Orban**, Département de psychiatrie et d'addictologie, UdeM




**CENTRE
DE RECHERCHE
DE L'USMM**
CENTRE AFFILIÉ À
L'UNIVERSITÉ DE MONTRÉAL



Phénomènes dynamiques

Le **stress** et l'**humeur** fluctuent à différentes échelles (jours, semaines, mois) et influencent la **qualité de vie** et le niveau de **fonctionnement**.



Motivation à prédire

Prédire le **stress** ou l'**humeur** permettrait la mise en place de stratégies préventives.



Phénotypage digital

Les téléphones intelligents permettent l'acquisition de données :

- ▶ **Passives;**
- ▶ **Écologiques;**
- ▶ **Longitudinales.**



Apprentissage automatique

L'**apprentissage automatique** sert à identifier des patrons complexes parmi les mégadonnées permettant de formuler des **prédictions individuelles généralisables**.



Objectifs de recherche

1. Prédictiones justes du **stress** et de l'**humeur** quotidiens à partir de données de **phénotypage digital**.



Friends and Family, 2010-2011

Participation de **142 adultes** de la population générale



Acquisition sur **8 mois**, soit **12 315** jours de données

Stress et **humeur** (*happiness*) quotidiens de 1 à 7:



- **1** : Very unstressed / unhappy;
- **4** : Neither stressed / happy, nor unstressed / unhappy;
- **7** : Very stressed / happy

(pour plus de details, voir
Aharony et al., 2011)

Données de phénotypage digital

- ▶ Historique d'**appels** et de **SMS**
- ▶ Scan **Bluetooth** de détection d'appareils
- ▶ Scan **Wi-Fi** de détection de réseaux
- ▶ Coordonnées **GPS**
- ▶ **Accéléromètre**
- ▶ Utilisation des **applications**
- ▶ Utilisation de la **batterie**



37 variables en entrées
(*attributs*)

Objectifs de recherche

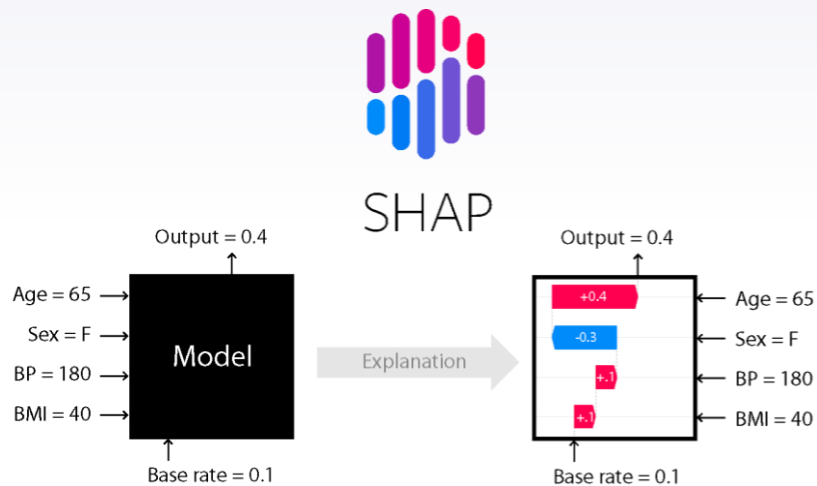
2.1 Identifier **quelles données** de phénotypage digital contribuent à de bonnes prédictions

2.2 Déterminer si les **mesures à forte composante sociale** y contribuent particulièrement.



► Expliquer un modèle

Les **valeurs de Shapley** permettent d'expliquer ce qu'a appris le modèle et ce qui contribue à une prédiction (*explication locale*)



Dimension sociale

Activité sociale :

Combien d'heures avez-vous passé à participer à des activités sociales (à l'extérieur de votre résidence)?

- <1 heure
- 1, 2, 3 heure(s)
- >3 heures



Entrainement des modèles

Classification binaire du stress et de l'humeur



Stress: 9735 jours

- Stressed (5-7) : 4457 jours
- Not stressed (1-3) : 5278 jours

Humeur (*Happiness*): 9759 jours


- Happy (5-7) : 7960 jours
- Not happy (1-3) : 1799 jours

Utilisation de **réseaux de neurones récurrents (RNN)** à partir d'une **séquence de 7 jours**




Performance des modèles




Stress : 75% des prédictions sont correctes (*justesse*)



Humeur : 72% des prédictions sont correctes (*justesse*)






Explication des prédictions - Stress



Kendall's tau = 0.047, $p = 0.69$

Explication des prédictions - Humeur



Kendall's tau = 0.041, $p = 0.72$

Conclusions

1. Bonne **performance prédictive** significativement au-dessus du niveau de la chance
2. L'**interprétation** des modèles prédictifs ne met pas de l'avant un rôle prépondérant pour les capteurs reflétant la dimension sociale



▶ Développements futurs

- ▶ **Étendre la portée** des prédictions à quelques jours, une semaine, un mois, etc.
- ▶ Prédire et anticiper des **événements cliniques majeurs** populations avec un **diagnostic psychiatrique** (étude en cours)
- ▶ Concevoir et valider des **mesures interprétables** de **l'activité sociale** à partir des capteurs bruts (Bluetooth, GPS, etc.)

Merci

Un grand merci à mes collègues

Rose Guay Hottin, Shivam Patel et Karthik Mukkavilli

Et à mon superviseur **Pierre Orban**

pour me contacter :

thierry.jean@umontreal.ca



PREVANTI



Centre intégré
universitaire de santé
et de services sociaux
de l'Est-de-
l'île-de-Montréal

Québec



**CENTRE
DE RECHERCHE
DE L'IUSMM**

CENTRE AFFILIÉ À
L'UNIVERSITÉ DE MONTRÉAL

Université 
de Montréal

impact⁸
esplanade

Références

- Abdullah, S. et Choudhury, T. (2018). Sensing Technologies for Monitoring Serious Mental Illnesses, *IEEE MultiMedia*, 25(1) 61-75. <https://doi.org/10.1109/MMUL.2018.011921236>
- Aharony, N., Pan, W., Ip, C., Khayal, I. et Pentland, A. (2011). Social fMRI: Investigating and shaping social mechanisms in the real world. *Pervasive and Mobile Computing*, 7(6), 643-659. <https://doi.org/10.1016/j.pmcj.2011.09.004>
- Bougeard, A., Guay Hottin, R., Houde, V., Jean, T., Potvin, S., Bernard, P., Tourjman, V., De Benedictis, L. et Orban, P. (2020). *Le phénotypage digital pour une pratique clinique en santé mentale mieux informée*. Document soumis pour publication
- Chiu, M., Gatov, E., Vigod, S. N., Amartey, A., Saunders, N. R., Yao, Z., et al. (2018). Temporal Trends in Mental Health Service Utilization across Outpatient and Acute Care Sectors: A Population-Based Study from 2006 to 2014. *The Canadian Journal of Psychiatry*, 63(2), 94-102. <http://doi.org/10.1177/0706743717748926>
- Cohen, A. S., Fedechko, T., Schwartz, E. K., Le, T. P., Foltz, P. W., Bernstein, J., et al. (2019). Psychiatric Risk Assessment from the Clinician's Perspective: Lessons for the Future. *Community Mental Health Journal*, 55(7), 1165-1172. <http://doi.org/10.1007/s10597-019-4380-4>
- Garcia-Ceja, E., Riegler, M., Nordgreen, T., Jakobsen, P., Oedegaard, K.J. et Tørresen, J. (2018). Mental health monitoring with multimodal sensing and machine learning: A survey. *Pervasive and Mobile Computing*, 51, 1-26. <https://doi.org/10.1016/j.pmcj.2018.09.003>
- Jaques, N., Rudovic, O., Taylor, S., Sano, A., & Picard, R. (2017). *Predicting Tomorrow's Mood, Health, and Stress Level using Personalized Multitask Learning and Domain Adaptation*. In Proceedings of IJCAI 2017 Workshop on Artificial Intelligence in Affective Computing, PMLR 66, 17-33.

Références

- Lundberg, S. (2020) *slundberg/shap* (0.37.0) [package Python]. GitHub. <https://github.com/slundberg/shap>
- Rohani, D.A., Faurholt-Jepsen, M., Kessing, L.V., et Bardram, J.E. (2018). Correlations Between Objective Behavioral Features Collected From Mobile and Wearable Devices and Depressive Mood Symptoms in Patients With Affective Disorders: Systematic Review. *JMIR Mhealth Uhealth*, 6(8). <https://doi.org/10.2196/mhealth.9691>
- Torous, J., et Baker, J.T. (2016). Why Psychiatry Needs Data Science and Data Science Needs Psychiatry: Connecting With Technology. *JAMA Psychiatry*, 73(1), 3-4. <https://doi.org/10.1001/jamapsychiatry.2015.2622>
- Wang, R., Chen, F., Chen, Z., Li, T., Harari, G., Tignor, S., Zhou, X., Ben-Zeev, D., et Campbell, A.T. (2014). *StudentLife*. Paper presented at the Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing - UbiComp '14 Adjunct. <http://doi.org/10.1145/2632048.2632054>
- Wright, A. G. C., et Woods, W. C. (2020). Personalized Models of Psychopathology. *Annual Review of Clinical Psychology*, 16, 49-74. <https://doi.org/10.1146/annurev-clinpsy-102419-125032>
- Zulueta, J., Leow, A. D., & Ajilore, O. (2020). Real-Time Monitoring: A Key Element in Personalized Health and Precision Health. *Focus*, 18(2), 175-180. <https://doi.org/10.1176/appi.focus.20190042>